

基于SOP的角色化农业咨询对话生成数据集

项目报告

一、引言

1.1 选题背景

随着大语言模型技术的快速发展，基于大模型的农业智能体咨询系统成为提升农业知识服务水平的重要方向。然而，高质量的中文农业问答数据是训练此类系统的核心基础，当前该领域面临以下突出问题。

第一，数据总量有限且作物覆盖不均衡。 现有数据集多集中于水稻、玉米等主粮作物，而甘蔗等经济作物及特定病害管理场景缺乏可用的问答数据，导致面向长尾作物的智能咨询能力严重不足。

第二，数据风格与真实农民提问方式存在鸿沟。 现有数据多来源于技术文档，风格偏书面化，而真实农民提问具有口语化、碎片化、信息不完整等特点，导致基于此类数据训练的模型难以理解农民的真实意图。

第三，生成结果的评测手段缺失。 农业问答专业性极强，传统自动化评测指标无法准确反映答案的语义正确性和专业完整性，而完全依赖人工评测成本过高。

国际前沿研究同样揭示了这一问题的重要性。AIFARMS团队在NeurIPS 2025上发表的MIRAGE基准指出：即使是当前最先进的模型，面对技术上复杂的农业问题时也难以保持准确性。MIRAGE基于35,000段真实对话构建，揭示了现有模型在农业专业推理方面的不足。AgMMU基准基于116,231段对话，同样揭示了模型在事实扎根方面的显著差距。

1.2 研究意义

本项目以甘蔗种植为场景，聚焦于“有据可循”和“场景真实”两个核心诉求：让每个问题都能追溯至明确的技术规程，同时让对话体现不同农户风格和自然的信息传递过程。

研究意义体现在三个方面：第一，为农业智能体提供兼具专业准确性与口语真实性的训练数据；第二，探索从结构化SOP知识到自然对话的生成范式，形成可复用的方法论；第三，回应MIRAGE等国际基准对农业AI评估的数据需求，为农业对话系统提供评测资源。

二、相关工作

2.1 农业问答数据集现状

现有农业问答数据集主要分两类。一类基于技术文档构建，风格书面化，与真实农民提问存在差距。另一类基于真实问答社区（如“农技耘”等平台），语言风格更真实，但缺乏结构化知识约束，答案的专业准确性难以保证。

国际上，MIRAGE和AgMMU代表了农业AI评估的前沿。MIRAGE包含单轮和多轮两种任务，不仅评估准确性，还评估模型模拟专家对话决策的能力。其核心特征是“信息不充分、上下文丰富”的开放场景，要求模型推断知识缺口并主动引导交互。然而，这些基准主要用于**评估**而非**训练**。本项目聚焦于为农业对话系统训练提供大规模、角色化的中文对话数据。

2.2 MIRAGE对SOP设计的启示

MIRAGE提出了三项核心交互模式：**对话状态追踪**（记住已获得和仍缺失的信息）、**目标驱动生成**（每轮回答始终朝向解决问题推进）、**专家级对话决策**（判断何时追问、何时给出方案）。这些启示直接指导了本项目的SOP设计——将SOP构建为包含“诊断标准—信息缺口策略—响应方案矩阵”三层结构的可执行知识表示。

三、SOP提取：从非结构化文档到结构化知识

SOP是农业领域针对特定农事操作（如病害防治、施肥、整地、收获等）制定的标准化步骤和规范。一份完整的SOP通常包含三部分：**诊断/判断标准**（如何识别问题）、**操作步骤**（具体怎么做）、**安全边界**（不能做什么）。例如，对于“甘蔗梢腐病”，SOP会明确其症状特征（心叶黄褐色斑）、防治时机（发病初期）和具体用药方案（苯醚甲环唑1000倍液，间隔7天一次，连喷2次）。SOP的核心价值在于：它是**有据可循**的专业知识载体，所有建议都能追溯到明确的规程依据。

但在原始文档中，SOP以非结构化段落呈现，层级混乱、条件分支隐式存在，无法直接用于模型的可执行推理。因此，本项目的首要任务是将非结构化文档转化为结构化SOP。

3.1 问题定义

SOP文档包含严格的诊断条件、处理步骤和安全边界，但原始文本以非结构化段落呈现，层级混乱、条件分支隐式存在。具体挑战包括：层级信息隐式存在（“发病初期”“严重期”等条件分散在自然语言中）、关键信息散落各处（药剂名称、剂量、时机需要跨句整合）、追问点不明确（文档说明“如何做”，未说明“何时追问什么”）。

3.2 技术路线

SOP提取分为三步：

第一步：规则分割。针对不同文档结构（病虫害按病名切分，操作规程按数字编号）编写正则规则，将长文本拆分为独立技术单元，自动标记类型（病害/虫害/栽培管理/灾害应对）。

第二步：结构化抽取。为每个单元构造含严格JSON Schema的提示词，要求模型按“元信息—诊断标准—信息缺口策略—响应方案矩阵”四段结构输出，强制生成2-3个条件分支，约束模型不得添加SOP之外的药剂或剂量。

第三步：容错处理。对返回文本进行代码块清洗、尾随逗号移除，确保JSON稳定解析。

3.3 SOP结构设计

基于MIRAGE的启示，本项目将SOP设计为三层结构：

第一层：诊断标准 (diagnosis_criteria)。包含症状描述、发生诱因、推理链和置信度。这一层的核心作用是为模型提供“什么症状对应什么问题”的判断依据。以甘蔗梢腐病为例，推理链明确写道：“如果观察到心叶黄褐色斑且扩展后呈梭形/长条形（中央灰白边缘暗红），同时近期高温多湿或偏施氮肥，则可判定为梢腐病。”

第二层：信息缺口策略 (missing_info_strategy)。包含关键信息 (key_entities) 和可选信息 (optional_entities)，以及对应的追问话术模板 (clarification_templates)。这一层直接回应MIRAGE的“对话状态追踪”要求。例如，对于梢腐病，关键信息包括“病情阶段”（初期/中期/严重期）和“环境湿度”（是否连续阴雨），追问话术分别为“发病是刚开始只有零星小斑，还是已经大面积烂心了？”和“最近雨水多吗？地里有没有积水？”

第三层：响应方案矩阵 (response_matrix)。包含多个场景 (scenarios) 和默认回复 (default_response)。每个场景由条件检查 (condition_checks)、响应类型 (complete_solution / partial_solution_with_clarification / alternative_solution)、操作内容和备用方案组成。这一层直接回应MIRAGE的“目标驱动生成”和“专家级对话决策”要求。

3.4 抽取效果

项目从10份来源文档（包括《甘蔗病虫害防治图谱》《贵港大岭基地糖蔗种植规程》《采收贮藏》《防风防霜冻》《风灾》《抗旱防涝》《砍运》等）中抽取了**93个结构化SOP单元**，覆盖病害、虫害、栽培管理、天气灾害、收获储存五大类别。

四、对话生成：从SOP到角色化多轮对话

4.1 生成框架设计

对话生成的整体框架基于“角色化 + SOP约束 + 多轮交互”三个核心设计原则。

角色化。真实农业咨询中，不同农户的提问风格、信息完整度和关注重点差异极大。新手可能描述零散、信息不全；经验型农户可能凭经验说话、跳过常识；合作社负责人可能关注成本和执行效率；灾后恢复户可能语气急切、信息混乱。如果生成的数据只有一种“标准农民”风格，模型将无法适应真实场景的多样性。

为此，本项目设计了**6种农户角色卡片**和**4种专家角色卡片**：

- **农户角色**：新手返乡承包户（F01）、经验型小农（F02）、合作社负责人（F03）、成本敏感散户（F04）、灾后恢复户（F05）、代管田块人员（F06）。每个角色定义了经验水平、生产背景、核心目标、决策压力、沟通风格、开场偏好和信息披露习惯。
- **专家角色**：基层农技推广员（E01）、植保专家（E02）、栽培管理专家（E03）、灾害应急指导员（E04）。每个角色定义了专业领域、沟通风格、追问风格和建议风格。

SOP约束。所有专家的回答必须严格遵循对应SOP的内容边界——不能添加SOP之外的药剂、剂量或操作步骤。这一约束通过在提示词中嵌入完整SOP并强制要求“只输出SOP支持范围内的建议”来实现。

多轮交互。对话不限于单轮问答，而是模拟真实咨询中的多轮信息收集过程。专家根据SOP中的信息缺口策略，在信息不足时主动追问，在信息齐全时给出最终方案。

4.2 生成流程

对话生成采用“角色路由 → 初始提问 → 多轮交互 → 终止判断”的四阶段流程。

角色路由。对每个SOP，首先调用大模型进行专家角色路由——根据SOP的内容特征（病害诊断 → 植保专家；栽培管理 → 栽培管理专家；灾害应对 → 灾害应急指导员），从4种专家角色中选择最匹配的一个。这一步骤确保了“什么问题由什么类型的专家回答”的专业匹配。

初始提问。根据随机选定的农户角色和SOP中的症状种子，生成农民的第一轮提问。提问被要求“口语化、信息不完整、有观察有担心”，模拟真实咨询中农民不会一次性说全所有信息的习惯。

多轮交互。每一轮中，专家根据当前对话历史和SOP判断信息是否充足。若不足，则从SOP的 clarification_templates 中选择或生成1-2个追问；若充足，则以 [FINAL_ANSWER] 标记输出最终方案。农民则根据专家的追问，以同一角色身份补充信息。循环持续到专家给出最终方案或达到最大轮数（10轮）。

终止判断。对话终止条件为专家回复中包含 [FINAL_ANSWER] 标记。这一机制确保了每条对话都有明确的“问题解决”终点，而非无限延续。

4.3 技术实现

- **多API Key并发**：10个Key轮询分配，ThreadPoolExecutor实现20线程并发
- **重试与容错**：每条对话失败自动重试2次；API调用失败重试3次
- **线程本地存储**：每个线程独立持有OpenAI客户端和API Key

4.4 生成效果

从93个SOP单元生成**2000+条**角色化多轮对话，每条含2-10轮交互，平均4-5轮。农户角色的多样性确保了风格变化，SOP约束保证了专业准确性。

五、数据集分析与质量评估

5.1 数据集规模与构成

维度	数据
SOP来源文档	10份
结构化SOP单元	93个
生成对话总数	2000+条
农户角色类型	6种
专家角色类型	4种
覆盖问题类别	病害、虫害、栽培管理、灾害、收获
对话格式	JSONL

每条记录包含 `schema_version`、`sop_id`、`profile`（角色信息）和 `dialog`（多轮对话数组）。

5.2 语言多样性评估

为量化评估数据集的语言多样性，从两个维度进行了分析：

压缩比 (Compression Ratio)：将所有对话拼接后用gzip压缩，计算压缩后与压缩前的字节数比值。该指标衡量词法和句式的重复程度，比值越低说明词汇和句式越丰富。

语义同质化分数 (Homogenization Score)：随机采样对话，计算每对文本之间的BERTScore F1，取所有对的平均值。该指标衡量语义内容的差异程度，分数越低说明对话间的内容差异越大。

对57个JSONL文件（包含2000+条对话）的评估结果显示：压缩比为0.42，同质化分数为0.40，与真实对话的参考范围（压缩比0.35-0.45，同质化分数0.30-0.40）基本一致。这表明本数据集在词汇丰富度和语义多样性上接近真实对话水平，6种农户角色的设计有效避免了生成数据的单一化。

5.3 质量保证机制

三层机制保证质量：**SOP层面**——专家回答必须基于SOP的诊断标准和响应方案；**生成过程**——异常回复触发重试，无最终方案标记则重新生成；**人工抽检**——定期检查对话自然性、答案准确性和角色一致性。

5.4 与MIRAGE基准的对齐

MIRAGE评估能力	本数据集的对应设计
对话状态追踪	<code>missing_info_strategy.key_entities</code> 定义信息清单
目标驱动生成	<code>response_matrix</code> 定义不同状态下的回答类型
专家级对话决策	<code>clarification_templates</code> 和 <code>default_response</code> 预设追问策略

六、总结

本项目围绕“有据可循”和“场景真实”两个核心诉求，完成了一套完整的农业咨询对话数据集构建流程：

在SOP提取方面，从非结构化的农业技术文档出发，通过规则分割和结构化抽取，将93个技术单元转化为包含诊断标准、信息缺口策略和响应方案矩阵的三层结构化SOP，为对话生成提供了可执行的知识底座。

在对话生成方面，设计了6种农户角色和4种专家角色的角色化生成框架，通过SOP约束保证答案准确性、通过角色多样性保证对话自然性，生成了超过2000条多轮农业咨询对话。

在技术实现方面，构建了多API Key并发的批量生成管线，支持自动重试和容错处理，实现了从SOP到对话数据的大规模、高质量产出。

分工说明：本项目三人协作完成，袁璐负责SOP抽取与结构化设计（文档预处理、Schema设计、提示词迭代与抽取），师露文负责对话生成与角色体系设计（角色卡片、角色路由、多轮生成提示词），卫怡璇负责批量生成管线与质量控制（并发调度、重试机制、2000+条数据生成与统计分析）。三人共同参与方案设计、讨论、汇报与报告撰写。